

1. Pengertian Data Cleaning

Data Cleaning adalah proses membersihkan data dari kesalahan, duplikasi, data kosong, dan data tidak valid sebelum dilakukan analisis.

Tujuan:

Meningkatkan kualitas data

Mengurangi kesalahan analisis

Meningkatkan akurasi model

2. Mengapa Data Cleaning Penting

Dalam dunia nyata, data sering mengandung:

Missing Value

Duplikasi

Outlier

Kesalahan Penulisan

Data Tidak Konsisten

3. Contoh Data Kotor

Nama	Umur	Nilai
Andi	20	85
Budi	-5	90
Andi	20	85
Caca	NULL	88

-
- Masalah:
- Umur negatif
 - Data duplikat
 - Missing value

4. Data Preprocessing

Data Preprocessing adalah proses menyiapkan data agar siap digunakan dalam analisis atau machine learning.

-
- Tahapan umum:
- Data Cleaning
 - Transformasi Data

Encoding

Normalisasi

Feature Selection

5. Missing Value

Missing Value adalah data yang hilang atau kosong.

Contoh:

Nama	Umur
Andi	20
Budi	NULL
Caca	19

6. Penyebab Missing Value

Kesalahan Input

Sensor Rusak

Data Tidak Tersedia

Kesalahan Sistem

7. Mendeteksi Missing Value

Menggunakan Pandas:

```
df.isnull()
```

8. Menghitung Missing Value

```
df.isnull().sum()
```

9. Menghapus Missing Value

```
df.dropna()
```

10. Mengisi Missing Value

Contoh:

```
df.fillna(0)
```

11. Mengisi dengan Mean

```
df["Nilai"].fillna(  
    df["Nilai"].mean()  
)
```

12. Mengisi dengan Median

```
df["Nilai"].fillna(  
    df["Nilai"].median()  
)
```

13. Mengisi dengan Modus

```
df["Kota"].fillna(  
    df["Kota"].mode()[0]  
)
```

14. Data Duplikat

Duplikat adalah data yang muncul lebih dari satu kali.

Contoh:

Andi 20

Andi 20

15. Mendeteksi Duplikat

```
df.duplicated()
```

16. Menghapus Duplikat

```
df.drop_duplicates()
```

17. Data Tidak Konsisten

Contoh:

Bandung

bandung

BANDUNG

Semua memiliki arti sama.

18. Menyeragamkan Teks

```
df["Kota"] = df["Kota"].str.lower()
```

19. Menghapus Spasi Berlebih

```
df["Nama"] = df["Nama"].str.strip()
```

20. Outlier

Outlier adalah data yang nilainya jauh berbeda dari mayoritas data.

Contoh:

20

21

22

19

18

250

Nilai:

250

adalah outlier.

21. Dampak Outlier

Mengubah rata-rata

Menurunkan akurasi model

Menyebabkan bias

22. Metode Deteksi Outlier

Metode umum:

IQR

Z-Score

23. IQR

IQR:

$Q3 - Q1$

24. Rumus Batas Outlier

Batas bawah:

$Q1 - 1.5 \times IQR$

Batas atas:

$Q3 + 1.5 \times IQR$

25. Encoding

Encoding adalah proses mengubah data kategorikal menjadi angka.

Contoh:

Laki-Laki

Perempuan

Menjadi:

0

1

26. Label Encoding

Setiap kategori diberi angka.

Contoh:

Merah → 0

Hijau → 1

Biru → 2

27. One Hot Encoding

Membuat kolom baru untuk setiap kategori.

Contoh:

Merah

Hijau

Biru

Menjadi:

Merah	Hijau	Biru
1	0	0
0	1	0
0	0	1

28. One Hot Encoding dengan Pandas

`pd.get_dummies(df)`

29. Feature Scaling

Feature Scaling adalah proses menyamakan skala data.

Contoh:

Umur = 20

Gaji = 10000000

Skala sangat berbeda.

30. Mengapa Scaling Penting

Beberapa algoritma sensitif terhadap skala data.

Contoh:

KNN

SVM

Neural Network

31. Normalisasi

Mengubah data ke rentang:

0 sampai 1

32. Rumus Min-Max Normalization

33. Standardisasi

Mengubah data agar memiliki:

Mean = 0

Standar Deviasi = 1

34. Rumus Standardisasi

35. Feature Selection

Feature Selection adalah proses memilih atribut yang paling relevan.

Tujuan:

Mengurangi dimensi data

Mempercepat training

Mengurangi overfitting

36. Contoh Feature Selection

Dataset mahasiswa:

Nama

NIM

Umur

Nilai

IPK

Mungkin:

Nama

NIM

tidak digunakan untuk prediksi.

37. Train dan Test Data

Sebelum Machine Learning:

Dataset dibagi menjadi:

Training Data

Testing Data

38. Rasio Pembagian Data

Umumnya:

80 : 20

70 : 30

39. train_test_split

Menggunakan Scikit-Learn:

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y,  
    test_size=0.2  
)
```

40. Tujuan Data Preprocessing

Data lebih bersih

Data lebih konsisten

Model lebih akurat

Analisis lebih terpercaya

Soal Bab 3

Soal 1

Apa yang dimaksud dengan Data Cleaning?

Soal 2

Mengapa Data Cleaning penting sebelum analisis data?

Soal 3

Jelaskan apa yang dimaksud dengan Missing Value.

Soal 4

Tuliskan tiga cara menangani Missing Value.

Soal 5

Bagaimana cara mendeteksi dan menghapus data duplikat menggunakan Pandas?

Soal 6

Apa yang dimaksud dengan Outlier?

Soal 7

Jelaskan metode IQR untuk mendeteksi outlier.

Soal 8

Bandingkan:

Label Encoding

One Hot Encoding

Soal 9

Mengapa Feature Scaling diperlukan?

Soal 10

Jelaskan perbedaan:

Normalisasi

Standardisasi

Soal 11

Apa yang dimaksud dengan Feature Selection?

Soal 12

Mengapa dataset perlu dibagi menjadi Training Data dan Testing Data?

Soal 13

Jelaskan fungsi:

`train_test_split()`

Soal 14

Sebutkan tahapan utama dalam Data Preprocessing.

Soal 15

Analisis dampak jika data kotor langsung digunakan untuk Machine Learning tanpa preprocessing.

BAB 3 selesai.

Selanjutnya: BAB 4 — Statistik Dasar untuk Data Science.