

Data Science

BAB 4 — Statistik Dasar untuk Data Science

1. Pengertian Statistik

Statistik adalah ilmu yang mempelajari cara mengumpulkan, mengolah, menganalisis, dan menginterpretasikan data.

Dalam Data Science, statistik digunakan untuk:

Memahami data

Menemukan pola

Membuat kesimpulan

Mendukung pengambilan keputusan

2. Statistik Deskriptif dan Inferensial

Statistik dibagi menjadi:

Statistik Deskriptif

Statistik Inferensial

3. Statistik Deskriptif

Digunakan untuk merangkum dan menggambarkan data.

Contoh:

Mean

Median

Modus

Diagram

Tabel

4. Statistik Inferensial

Digunakan untuk menarik kesimpulan dari sampel ke populasi.

Contoh:

Uji Hipotesis

Regresi

Estimasi

5. Populasi

Populasi adalah seluruh objek yang menjadi sasaran penelitian.

Contoh:

Seluruh mahasiswa UPI

6. Sampel

Sampel adalah sebagian anggota populasi yang mewakili populasi.

Contoh:

200 mahasiswa UPI

7. Variabel

Variabel adalah karakteristik yang diamati dalam penelitian.

Contoh:

Umur

IPK

Tinggi Badan

8. Skala Data

Empat jenis skala data:

Nominal

Ordinal

Interval

Rasio

9. Skala Nominal

Hanya digunakan untuk membedakan kategori.

Contoh:

Jenis Kelamin

Agama

Program Studi

10. Skala Ordinal

Memiliki urutan tetapi selisihnya tidak pasti.

Contoh:

Rangking

Tingkat Kepuasan

11. Skala Interval

Memiliki jarak yang sama tetapi tidak memiliki nol mutlak.

Contoh:

Suhu Celsius

12. Skala Rasio

Memiliki nol mutlak.

Contoh:

Berat Badan

Umur

Pendapatan

13. Ukuran Pemusatan Data

Digunakan untuk mengetahui nilai pusat data.

Meliputi:

Mean

Median

Modus

14. Mean

Mean adalah rata-rata data.

Rumus:

15. Contoh Mean

Data:

10 20 30 40 50

Perhitungan:

$$(10+20+30+40+50)/5$$

Hasil:

30

16. Median

Median adalah nilai tengah setelah data diurutkan.

Contoh:

10 20 30 40 50

Median:

30

17. Median untuk Jumlah Data Genap

Data:

10 20 30 40

Median:

$(20+30)/2$

Hasil:

25

18. Modus

Modus adalah nilai yang paling sering muncul.

Contoh:

10 20 20 20 30

Modus:

20

19. Ukuran Penyebaran Data

Digunakan untuk melihat seberapa tersebar data.

Contoh:

Range

Varians

Standar Deviasi

20. Range

Range adalah selisih antara nilai terbesar dan terkecil.

Rumus:

$\text{Range} = \text{Max} - \text{Min}$

21. Contoh Range

Data:

10 20 30 40 50

Range:

$$50 - 10 = 40$$

22. Varians

Varians mengukur penyebaran data terhadap rata-rata.

Rumus:

23. Standar Deviasi

Standar deviasi adalah akar kuadrat dari varians.

Rumus:

24. Interpretasi Standar Deviasi

Standar deviasi kecil:

Data berdekatan dengan rata-rata

Standar deviasi besar:

Data lebih menyebar

25. Kuartil

Kuartil membagi data menjadi empat bagian.

Terdiri dari:

Q1

Q2

Q3

26. Q1

Kuartil pertama.

Menunjukkan:

25% data berada di bawahnya

27. Q2

Kuartil kedua.

Sama dengan:

Median

28. Q3

Kuartil ketiga.

Menunjukkan:

75% data berada di bawahnya

29. IQR

Interquartile Range.

Rumus:

30. Distribusi Data

Distribusi menunjukkan bagaimana data tersebar.

31. Distribusi Normal

Distribusi berbentuk lonceng (*bell curve*).

Karakteristik:

Mean = Median = Modus

32. Distribusi Miring Kanan

(*Positive Skew*)

Ciri:

Mean > Median

33. Distribusi Miring Kiri

(*Negative Skew*)

Ciri:

Mean < Median

34. Korelasi

Korelasi mengukur hubungan antar variabel.

Nilai korelasi:

-1 sampai 1

35. Korelasi Positif

Jika satu variabel naik, variabel lain ikut naik.

Contoh:

Jam Belajar

Nilai Ujian

36. Korelasi Negatif

Jika satu variabel naik, variabel lain turun.

Contoh:

Kecepatan

Waktu Tempuh

37. Tidak Ada Korelasi

Dua variabel tidak memiliki hubungan jelas.

38. Korelasi Bukan Kausalitas

Korelasi tidak selalu berarti sebab-akibat.

Contoh:

Penjualan Es Krim ↑

Kasus Tenggelam ↑

Keduanya dipengaruhi oleh:
Musim Panas

39. Statistik dengan Pandas

Mean:

```
df["Nilai"].mean()
```

Median:

```
df["Nilai"].median()
```

Standar Deviasi:

```
df["Nilai"].std()
```

40. Peran Statistik dalam Data Science

Memahami data

Mendeteksi anomali

Membantu preprocessing

Menjadi dasar Machine Learning

Soal Bab 4

Soal 1

Apa yang dimaksud dengan statistik?

Soal 2

Bandingkan:

Statistik Deskriptif

Statistik Inferensial

Soal 3

Jelaskan perbedaan:

Populasi

Sampel

Soal 4

Sebutkan dan jelaskan empat skala data.

Soal 5

Hitung mean dari data:

10 20 30 40 50

Soal 6

Hitung median dari data:

5 10 15 20 25

Soal 7

Tentukan modus dari data:

2 3 3 4 5 5 5 6

Soal 8

Jelaskan perbedaan:

Range

Varians

Standar Deviasi

Soal 9

Apa yang dimaksud dengan kuartil dan IQR?

Soal 10

Jelaskan karakteristik distribusi normal.

Soal 11

Bandingkan:

Korelasi Positif

Korelasi Negatif

Soal 12

Mengapa korelasi tidak selalu berarti kausalitas?

Soal 13

Jelaskan fungsi statistik dalam Data Science.

Soal 14

Bagaimana cara menghitung mean dan median menggunakan Pandas?

Soal 15

Analisis mengapa pemahaman statistik penting sebelum mempelajari Machine Learning.

BAB 4 selesai.

Selanjutnya: BAB 5 — Visualisasi Data dengan Matplotlib dan Seaborn.