

### 1. Pengertian EDA

Exploratory Data Analysis (EDA) adalah proses mengeksplorasi dan memahami data sebelum dilakukan pemodelan atau Machine Learning.

---

Tujuan EDA:

Memahami karakteristik data

Menemukan pola

Menemukan outlier

Menemukan hubungan antar variabel

Menemukan masalah pada data

---

### 2. Mengapa EDA Penting

Sebelum membuat model, kita harus memahami data terlebih dahulu.

---

Tanpa EDA:

Model dapat menghasilkan prediksi buruk

Masalah data tidak terdeteksi

---

### 3. Tahapan EDA

Secara umum:

Memahami Dataset

Menganalisis Struktur Data

Menganalisis Statistik

Visualisasi Data

Menarik Kesimpulan

---

### 4. Memuat Dataset

Menggunakan Pandas:

```
import pandas as pd
```

```
df = pd.read_csv("data.csv")
```

---

### 5. Menampilkan Data Awal

```
df.head()
```

---

Tujuan:

Melihat isi dataset

---

## 6. Menampilkan Data Akhir

`df.tail()`

---

## 7. Mengetahui Ukuran Dataset

`df.shape`

---

Contoh hasil:

`(1000,5)`

Artinya:

1000 baris

5 kolom

---

## 8. Mengetahui Nama Kolom

`df.columns`

---

## 9. Mengetahui Tipe Data

`df.dtypes`

---

## 10. Informasi Dataset

`df.info()`

---

Menampilkan:

Jumlah data

Tipe data

Missing value

---

## 11. Statistik Deskriptif

`df.describe()`

---

Menampilkan:

Mean

Min

Max

Std

Quartile

---

## 12. Menghitung Mean

```
df["Nilai"].mean()
```

---

## 13. Menghitung Median

```
df["Nilai"].median()
```

---

## 14. Menghitung Modus

```
df["Nilai"].mode()
```

---

## 15. Menghitung Nilai Maksimum

```
df["Nilai"].max()
```

---

## 16. Menghitung Nilai Minimum

```
df["Nilai"].min()
```

---

## 17. Menghitung Standar Deviasi

```
df["Nilai"].std()
```

---

## 18. Mengidentifikasi Missing Value

```
df.isnull().sum()
```

---

## 19. Mengidentifikasi Data Duplikat

```
df.duplicated().sum()
```

---

## 20. Analisis Distribusi Data

Distribusi data menunjukkan bagaimana data tersebar.

---

## 21. Histogram

Digunakan untuk melihat distribusi data.

---

Contoh:

```
import seaborn as sns

sns.histplot(df["Nilai"])
```

---

## 22. Interpretasi Histogram

Jika histogram simetris:

Distribusi mendekati normal

---

Jika miring:

Terdapat skewness

---

## 23. Box Plot

Digunakan untuk mendeteksi outlier.

---

```
sns.boxplot(y=df["Nilai"])
```

---

## 24. Outlier pada Box Plot

Titik yang berada di luar whisker biasanya dianggap outlier.

---

## 25. Analisis Variabel Kategorikal

Misalnya:

Jenis Kelamin

Program Studi

Kota

---

## 26. Menghitung Frekuensi Kategori

```
df["Prodi"].value_counts()
```

---

## 27. Visualisasi Frekuensi

```
sns.countplot(  
    x="Prodi",  
    data=df  
)
```

---

## 28. Analisis Hubungan Antar Variabel

EDA juga digunakan untuk melihat hubungan antar atribut.

---



## 29. Korelasi

Mengukur hubungan dua variabel numerik.

---

Nilai:

-1 sampai 1

---

## 30. Menghitung Korelasi

```
df.corr()
```

---

## 31. Interpretasi Korelasi

1 = Sangat Positif

0 = Tidak Berhubungan

-1 = Sangat Negatif

---

## 32. Heatmap Korelasi

```
sns.heatmap(  
    df.corr(),  
    annot=True  
)
```

---

### 33. Scatter Plot

Digunakan untuk melihat hubungan antar variabel.

---

Contoh:

```
sns.scatterplot(  
    data=df,  
    x="JamBelajar",  
    y="Nilai"  
)
```

---

### 34. Interpretasi Scatter Plot

Jika titik membentuk pola naik:

Korelasi Positif

---

Jika pola turun:

Korelasi Negatif

---

### 35. Grouping Data

Mengelompokkan data berdasarkan kategori.

---

Contoh:

```
df.groupby("Prodi").mean()
```

---

### 36. Agregasi Data

Fungsi agregasi:

```
sum()
```

```
mean()
```

```
max()
```

```
min()
```

```
count()
```

---

### 37. Crosstab

Digunakan untuk membandingkan dua kategori.

---

Contoh:

```
pd.crosstab(  
    df["Gender"],  
    df["Lulus"]  
)
```

---

### 38. Insight

Insight adalah informasi penting yang diperoleh dari data.

---

Contoh:

Mahasiswa yang belajar lebih lama  
cenderung memiliki nilai lebih tinggi

---

### 39. Tujuan Akhir EDA

Mengubah data mentah menjadi informasi yang mudah dipahami.

---

### 40. Peran EDA dalam Data Science

EDA membantu:

Memahami Data

Membersihkan Data

Menentukan Feature

Membuat Model yang Lebih Baik

---

## Soal Bab 6

### Soal 1

Apa yang dimaksud dengan Exploratory Data Analysis (EDA)?

---

### Soal 2

Mengapa EDA dilakukan sebelum Machine Learning?

---

### Soal 3

Jelaskan fungsi:

`head()`

`tail()`

`info()`

`describe()`

---

### Soal 4

Apa fungsi:

`shape`

`columns`

`dtypes`

---

### Soal 5

Bagaimana cara mendeteksi missing value menggunakan Pandas?

---

### Soal 6

Bagaimana cara mendeteksi data duplikat?

---

### Soal 7

Apa fungsi histogram dalam EDA?

---

### Soal 8

Apa fungsi box plot?

---

### Soal 9

Bagaimana cara menghitung korelasi antar variabel?

---

### Soal 10

Apa arti nilai korelasi:

1

0

-1

\_\_\_\_\_

### Soal 11

Apa fungsi heatmap korelasi?

\_\_\_\_\_

### Soal 12

Apa fungsi scatter plot dalam EDA?

\_\_\_\_\_

### Soal 13

Jelaskan fungsi:

`groupby()`

\_\_\_\_\_

### Soal 14

Apa yang dimaksud dengan insight dalam Data Science?

\_\_\_\_\_

### Soal 15

Analisis mengapa EDA sering dianggap sebagai tahap paling penting dalam proyek Data Science.

---

**BAB 6 selesai.**

**Selanjutnya: KUIS 1 (Bab 1–6).**