

Rangkuman Machine Learning Workflow (Catatan Belajar Sederhana)

Apa itu Machine Learning Workflow?

Machine Learning Workflow adalah urutan langkah-langkah yang dilakukan untuk membangun model machine learning, mulai dari pengumpulan data hingga model digunakan oleh pengguna. Alurnya bersifat **iteratif**, artinya jika hasil model belum baik, kita bisa kembali ke tahap sebelumnya untuk memperbaiki data, fitur, atau model.

Alur Machine Learning Workflow

1. Problem Understanding (Memahami Masalah)

Sebelum membuat model, kita harus memahami:

- Masalah apa yang ingin diselesaikan
- Tujuan bisnis yang ingin dicapai
- Output yang diharapkan

Contoh:

Masalah:

Banyak pelanggan berhenti berlangganan.

Tujuan:

Memprediksi pelanggan yang berpotensi berhenti agar dapat diberikan promosi.

2. Data Collecting (Pengumpulan Data)

Data adalah bahan bakar utama machine learning.

Data dapat diperoleh dari:

- Database
- API
- Website
- Sensor
- Dataset publik

Jenis data:

- Angka
- Teks
- Gambar
- Video
- Data kategori

Inti

Semakin berkualitas dan relevan data yang dikumpulkan, semakin baik model yang dihasilkan.

3. Data Loading

Setelah data dikumpulkan, data dimasukkan ke lingkungan kerja Python.

Biasanya menggunakan:

- Pandas
- NumPy

Contoh file:

- CSV
- Excel
- JSON
- Database SQL

Tujuan:

- Agar data dapat diproses dan dianalisis.

4. Data Cleaning & Transformation

Tahap membersihkan data agar siap digunakan.

Masalah yang sering ditemukan:

Missing Value

Data kosong.

Contoh:

Nama	Umur
Andi	20
Budi	-

Duplicate Data

Data yang tercatat lebih dari sekali.

Data Tidak Konsisten

Contoh:

Pria

Laki-laki

Male

Semua memiliki arti sama tetapi format berbeda.

Transformation

Mengubah data agar mudah diproses model.

Contoh:

- Mengubah teks menjadi angka
- Normalisasi data

- Encoding kategori

Inti

Data mentah → Data bersih → Data siap digunakan.

5. Exploratory Data Analysis (EDA)

EDA adalah proses memahami data yang telah dibersihkan.

Tujuan:

- Menemukan pola
- Menemukan anomali
- Menemukan hubungan antar variabel
- Memahami distribusi data

EDA sering disebut tahap paling menarik dalam data science karena di sini kita mulai menemukan insight.

Jenis EDA

Univariate Analysis

Menganalisis satu variabel.

Contoh:

- Distribusi umur pelanggan
- Rata-rata pendapatan

Bivariate Analysis

Menganalisis dua variabel.

Contoh:

- Hubungan umur dan gaji

Multivariate Analysis

Menganalisis lebih dari dua variabel.

Contoh:

- Umur, gaji, pendidikan, dan tingkat pembelian

6. Explanatory Data Analysis (ExDA)

Jika EDA bertujuan mencari insight, maka ExDA bertujuan menyampaikan insight tersebut.

EDA

"Mencari jawaban"

ExDA

“Menjelaskan jawaban”

Biasanya menggunakan:

- Dashboard
- Grafik
- Presentasi
- Laporan

Tujuan:

- Membantu stakeholder memahami hasil analisis.

7. Data Splitting

Dataset dibagi menjadi beberapa bagian.

Training Set

Digunakan untuk melatih model.

Biasanya:

- 70%
- 80%

Validation Set

Digunakan untuk tuning model.

Biasanya:

- 10%
- 15%

Test Set

Digunakan untuk menguji model akhir.

Biasanya:

- 10%
- 20%

Tujuan

Agar model tidak hanya hafal data training tetapi juga mampu memprediksi data baru.

8. Model Selection

Tahap memilih algoritma terbaik.

Contoh algoritma:

Untuk Klasifikasi

- Logistic Regression
- Decision Tree
- Random Forest

Untuk Regresi

- Linear Regression
- Random Forest Regressor

Untuk Deep Learning

- Neural Network
- CNN
- RNN

Baseline Model

Biasanya mencoba beberapa algoritma dengan parameter default.

Tujuannya:

- Membandingkan performa awal
- Menentukan model yang layak dikembangkan

9. Model Training

Model belajar dari data training.

Tujuan:

- Menemukan pola
- Menyesuaikan parameter model
- Mengurangi error

Hasil:

- Model yang telah terlatih

10. Hyperparameter Tuning

Mengoptimalkan konfigurasi model.

Contoh hyperparameter:

- Learning Rate
- Jumlah Tree
- Kedalaman Tree
- Jumlah Epoch

Tujuan:

- Meningkatkan akurasi
- Mengurangi error

11. Model Evaluation

Setelah model dilatih, dilakukan evaluasi menggunakan data test.

Metrik yang sering digunakan:

Klasifikasi

- Accuracy
- Precision
- Recall
- F1 Score

Regresi

- MAE
- MSE
- RMSE

Tujuan:

- Mengetahui seberapa baik model bekerja.

12. Deployment

Deployment adalah proses menerapkan model ke dunia nyata.

Contoh:

- Sistem rekomendasi Netflix
- Deteksi spam email
- Prediksi harga rumah

Tujuan:

- Agar model dapat digunakan pengguna.

13. Monitoring

Setelah deployment, model harus terus dipantau.

Karena:

- Data dunia nyata terus berubah
- Pola baru bisa muncul
- Akurasi model dapat menurun

Masalah yang sering terjadi:

Data Drift

Data baru berbeda dari data saat training.

Contoh:

Model dilatih pada data tahun 2024 tetapi digunakan pada data tahun 2026.

Performance Degradation

Performa model menurun seiring waktu.

Solusi:

- Retraining model
- Update dataset

Tools untuk Machine Learning

Jupyter Notebook

Notebook interaktif untuk menulis dan menjalankan kode Python.

Kelebihan:

- Mudah digunakan
- Cocok untuk belajar dan eksperimen

Google Colab

Versi online dari notebook.

Kelebihan:

- Gratis
- Tidak perlu instalasi
- Mendukung GPU

IBM Watson Studio

Platform cloud dari IBM untuk data science dan machine learning.

Library Python yang Sering Digunakan

NumPy

Digunakan untuk:

- Operasi matematika
- Array multidimensi

Pandas

Digunakan untuk:

- Membaca data
- Mengolah data
- Analisis data

Struktur utama:

- DataFrame

Matplotlib

Digunakan untuk visualisasi data.

Contoh grafik:

- Histogram
- Scatter Plot
- Bar Chart
- Pie Chart

Scikit-Learn

Library machine learning paling populer untuk pemula.

Fitur:

- Preprocessing
- Training model
- Evaluasi model
- Hyperparameter tuning

TensorFlow

Framework machine learning dari Google.

Digunakan untuk:

- Deep Learning
- Computer Vision
- NLP

PyTorch

Framework deep learning dari Meta (Facebook).

Kelebihan:

- Fleksibel
- Banyak digunakan untuk penelitian

Keras

API tingkat tinggi di atas TensorFlow.

Kelebihan:

- Lebih sederhana
- Cepat membuat prototype

NLTK dan SpaCy

Digunakan untuk NLP (Natural Language Processing).

Contoh:

- Analisis sentimen
- Chatbot
- Penerjemah bahasa

SciPy

Digunakan untuk komputasi ilmiah.

Contoh:

- Optimisasi
- Statistik
- Pengolahan sinyal