

Rangkuman Supervised Learning - Klasifikasi (Catatan Belajar Sederhana)

1. Apa itu Klasifikasi?

Klasifikasi adalah metode Machine Learning yang digunakan untuk mengelompokkan data ke dalam kategori tertentu.

Klasifikasi termasuk **Supervised Learning**, artinya model belajar menggunakan data yang sudah memiliki label.

Contoh

Fitur	Label
Email A	Spam
Email B	Bukan Spam

Setelah belajar dari data tersebut, model dapat menentukan apakah email baru termasuk spam atau tidak.

Tujuan Klasifikasi

Memprediksi label atau kelas dari data baru berdasarkan pola yang dipelajari dari data latih.

2. Tahapan Klasifikasi

1. Pengumpulan Data

Mengumpulkan data yang relevan dan berkualitas.

Contoh:

- Data pasien
- Data email
- Data transaksi

2. Pra-pemrosesan Data

Membersihkan data sebelum digunakan.

Contoh:

- Menghapus duplikasi
- Mengatasi missing value
- Encoding data kategori
- Normalisasi

3. Pembagian Data

Dataset dibagi menjadi:

Training Data

Untuk melatih model.

Biasanya:

- 70%
- 80%

Testing Data

Untuk menguji model.

Biasanya:

- 20%
- 30%

4. Memilih Algoritma

Contoh:

- KNN
- Decision Tree
- Random Forest
- SVM
- Naive Bayes

5. Training Model

Model belajar pola dari data training.

6. Evaluasi Model

Mengukur performa model menggunakan:

- Accuracy
- Precision
- Recall
- F1 Score

7. Deployment

Model digunakan pada aplikasi nyata.

3. Jenis-Jenis Klasifikasi

A. Binary Classification

Hanya ada 2 kelas.

Contoh:

- Spam / Tidak Spam

- Sakit / Sehat
- Lulus / Tidak Lulus

B. Multiclass Classification

Lebih dari 2 kelas.

Contoh:

- Kucing
- Anjing
- Burung

C. Multilabel Classification

Satu data bisa memiliki beberapa label sekaligus.

Contoh:

Artikel berita:

- Teknologi
- Bisnis

Keduanya bisa benar secara bersamaan.

4. K-Nearest Neighbors (KNN)

Konsep Dasar

KNN bekerja berdasarkan:

"Tetangga yang paling dekat."

Jika mayoritas tetangga adalah kelas A, maka data baru diprediksi sebagai kelas A.

Cara Kerja KNN

Langkah 1

Pilih nilai K.

Misal:

$$K = 3$$

Langkah 2

Hitung jarak data baru ke seluruh data.

Biasanya menggunakan:

- Euclidean Distance
- Manhattan Distance

Langkah 3

Ambil K tetangga terdekat.

Langkah 4

Voting mayoritas.

Contoh:

Tetangga :

A

A

B

Mayoritas A.

Prediksi = A.

Parameter Penting KNN

K (Jumlah Tetangga)

K kecil:

- Sensitif noise
- Overfitting

K besar:

- Lebih stabil
- Bisa underfitting

Metric Jarak

- Euclidean
- Manhattan
- Minkowski
- Cosine Similarity

Weights

Uniform:

- Semua tetangga dianggap sama

Distance:

- Tetangga yang lebih dekat lebih berpengaruh

Kelebihan KNN

- ✓ Mudah dipahami
- ✓ Cocok untuk pemula
- ✓ Tidak membutuhkan training rumit

Kekurangan KNN

- ✗ Lambat pada dataset besar
- ✗ Sensitif terhadap noise
- ✗ Wajib normalisasi data


5. Decision Tree

Konsep Dasar

Decision Tree bekerja seperti pohon keputusan.

Contoh:

Apakah umur > 18?



Cara Kerja

1. Memilih fitur terbaik
2. Membagi data
3. Membuat cabang
4. Diulang sampai mencapai leaf node

Parameter Penting

Criterion

Mengukur kualitas pembagian.

- Gini
- Entropy

max_depth

Kedalaman pohon.

Kecil:

- Underfitting

Besar:

- Overfitting

min_samples_split

Jumlah minimal data untuk membuat cabang baru.

min_samples_leaf

Jumlah minimal data pada daun.

Kelebihan

- ✓ Mudah dipahami
- ✓ Tidak perlu normalisasi
- ✓ Bisa menangani data numerik dan kategori

Kekurangan

- ✗ Rentan overfitting
- ✗ Pohon terlalu besar sulit dibaca

6. Random Forest

Konsep Dasar

Random Forest adalah kumpulan banyak Decision Tree.

Kalau Decision Tree seperti satu dokter.

Random Forest seperti 100 dokter yang memberikan pendapat lalu dilakukan voting.

Cara Kerja

1. Membuat banyak Decision Tree

Misalnya:

Tree 1

Tree 2

Tree 3

...

Tree 100

2. Setiap Tree belajar dari data acak

Menggunakan teknik:

Bootstrap Sampling

3. Voting

Misalnya:

A

A

B

A

Mayoritas A.

Prediksi akhir = A.

Parameter Penting

n_estimators

Jumlah pohon.

Biasanya:

100 – 300

max_depth

Kedalaman pohon.

min_samples_split

Minimal data untuk split.

max_features

Jumlah fitur yang dipilih secara acak.

Kelebihan



Akurasi tinggi



Tidak mudah overfitting



Dapat menangani data besar

Kekurangan

- ✗ Membutuhkan memori besar
- ✗ Sulit diinterpretasikan

7. Support Vector Machine (SVM)

Konsep Dasar

SVM mencari garis pemisah terbaik (hyperplane) antara dua kelas.

Contoh:

○ ○ ○ ○

■ ■ ■ ■

Garis pemisah dibuat agar jaraknya ke kedua kelas semaksimal mungkin.

Istilah Penting

Hyperplane

Garis pemisah antar kelas.

Support Vector

Data yang paling dekat dengan garis pemisah.

Margin

Jarak antara hyperplane dan support vector.

Semakin besar margin:

- Semakin baik generalisasi

Parameter Penting

Kernel

Digunakan jika data tidak dapat dipisahkan secara linear.

Jenis:

- Linear
- Polynomial

- RBF
- Sigmoid

C (Regularization)

Mengontrol overfitting.

C besar:

- Lebih ketat mengikuti data

C kecil:

- Lebih banyak regularisasi

Gamma

Mengontrol pengaruh titik data.

Kelebihan

- ✓ Bagus untuk data kecil
- ✓ Bagus untuk data berdimensi tinggi
- ✓ Akurat

Kekurangan

- ✗ Lambat pada dataset besar
- ✗ Sulit dipahami
- ✗ Tuning cukup sulit

8. Naive Bayes

Konsep Dasar

Berdasarkan Teorema Bayes.

Menghitung probabilitas suatu data masuk ke kelas tertentu.

Contoh:

Email mengandung:

Diskon

Promo

Gratis

Kemungkinan besar:

Spam

Asumsi Utama

Setiap fitur dianggap independen.

Itulah sebabnya disebut:

Naive (sederhana)

Cara Kerja

1. Hitung probabilitas kelas
2. Hitung probabilitas fitur
3. Gunakan Teorema Bayes
4. Pilih probabilitas terbesar

Kelebihan

- ✓ Cepat
- ✓ Sederhana
- ✓ Cocok untuk data teks

Kekurangan

- ✗ Asumsi independensi sering tidak realistis
- ✗ Kurang baik jika fitur saling berkaitan

9. Evaluasi Model Klasifikasi

Confusion Matrix

Tabel evaluasi untuk klasifikasi.

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP	FN
Aktual Negatif	FP	TN

TP (True Positive)

Positif diprediksi positif.

TN (True Negative)

Negatif diprediksi negatif.

FP (False Positive)

Negatif diprediksi positif.

(Type I Error)

FN (False Negative)

Positif diprediksi negatif.

(Type II Error)

10. Metrik Evaluasi

Accuracy

Persentase prediksi yang benar.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Digunakan ketika data seimbang.

Precision

Dari semua prediksi positif, berapa yang benar.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Fokus:

Jangan sampai salah menuduh positif.

Contoh:

- Deteksi spam
- Deteksi penipuan

Recall

Dari semua positif sebenarnya, berapa yang berhasil ditemukan.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Fokus:

Jangan sampai ada yang terlewat.

Contoh:

- Diagnosis kanker

F1 Score

Gabungan Precision dan Recall.

$$F1=2\frac{\text{Precision}\times\text{Recall}}{\text{Precision}+\text{Recall}}$$

Cocok untuk data tidak seimbang.