

Bagus, sekarang kita masuk ke **Unsupervised Learning - Clustering**.

Kalau klasifikasi itu:

“Saya sudah tahu labelnya, tolong pelajari polanya.”

Contoh:

Umur	Gaji	Beli Rumah
30	20 jt	Ya
25	10 jt	Tidak

Target (**Beli Rumah**) sudah ada.

Kalau **Clustering**:

“Saya tidak tahu labelnya, coba kelompokkan sendiri data yang mirip.”

Misalnya data pelanggan:

Umur	Penghasilan
20	5 jt
22	6 jt
45	30 jt
47	32 jt

Model akan menemukan bahwa:

Kelompok 1:

- umur muda
- gaji rendah

Kelompok 2:

- umur lebih tua
- gaji tinggi

Tanpa diberi tahu label apa pun.

1. Apa itu Clustering?

Clustering = proses mengelompokkan data yang mirip ke dalam satu grup (cluster).

Contoh sederhana:

Ada 100 pelanggan toko.

Kita belum tahu tipe pelanggan mereka.

Setelah clustering:

Cluster A

- umur 18-25
- sering belanja

Cluster B

- umur 40-55
- penghasilan tinggi

Cluster C

- jarang belanja

Nah perusahaan bisa membuat strategi berbeda untuk tiap kelompok.

2. Tahapan Clustering

Langkah 1: Kumpulkan Data

Misal:

Umur	Gaji
20	5
21	6
45	30
50	35

Langkah 2: Pilih Fitur

Tidak semua kolom digunakan.

Misalnya:

✓ umur

✓ gaji

Tapi:

✗ nomor pelanggan
karena tidak penting.

Langkah 3: Normalisasi

Misalnya:

Umur:

20 - 50

Gaji:

5 juta - 100 juta

Kalau tidak dinormalisasi:

Gaji akan mendominasi perhitungan jarak.

Makanya sering dilakukan:

- Min-Max Scaling
 - Standardisasi
-

Langkah 4: Hitung Jarak

Biasanya memakai Euclidean Distance.

Misal:

Pelanggan A:

(20, 5)

Pelanggan B:

(21, 6)

Jaraknya kecil → mirip.

Langkah 5: Bentuk Cluster

Menggunakan algoritma:

- K-Means
 - K-Medoids
 - DBSCAN
 - Mean Shift
 - Hierarchical
-

3. Hierarchical Clustering

Ini clustering berbentuk pohon.
Ada dua cara.

Agglomerative (Bottom-Up)

Mulai dari bawah.

Awalnya:

Setiap data adalah cluster sendiri.

A B C D

Cari yang paling dekat.

Misal:

A dan B dekat.

(A, B) C D

Lalu:

C dan D dekat.

(A, B) (C, D)

Lalu digabung lagi.

((A, B), (C, D))

Sampai menjadi satu cluster besar.

Divisive (Top-Down)

Kebalikannya.

Awalnya:

A B C D

satu cluster besar.


Lalu dipecah:

(A, B) (C, D)

Lalu dipecah lagi.

Dendrogram

Hierarchical Clustering biasanya digambar sebagai pohon:



Ini disebut **Dendrogram**.

Dendrogram membantu menentukan jumlah cluster.

4. K-Means

Ini algoritma clustering yang paling sering keluar di ujian.

Misal data:

A
B
C
D
E

Kita pilih:

$K = 2$

Artinya:

"Saya ingin membagi data menjadi 2 kelompok."

Cara Kerja K-Means

Langkah 1

Pilih jumlah cluster.

Misal:

$K = 2$

Langkah 2

Pilih centroid awal.

Centroid = titik pusat cluster.

Misal:

Centroid 1

Centroid 2

dipilih acak.

Langkah 3

Hitung jarak semua data ke centroid.

Misal:

A lebih dekat ke Centroid 1

B lebih dekat ke Centroid 1
C lebih dekat ke Centroid 2
D lebih dekat ke Centroid 2

Langkah 4

Hitung ulang centroid.
Karena anggota cluster berubah.
Centroid ikut bergeser.

Langkah 5

Ulang terus.
Sampai centroid tidak bergerak lagi.
Disebut:
Convergen

Kelebihan K-Means

- ✓ Cepat
 - ✓ Mudah
 - ✓ Cocok dataset besar
-

Kekurangan K-Means

- ✗ Harus menentukan K di awal
- ✗ Sensitif terhadap outlier

Contoh pertanyaan ujian:

K-Means membutuhkan parameter apa?

Jawaban:

☒ Jumlah cluster (**K**)

5. K-Medoids

Mirip K-Means.

Bedanya:

K-Means

Pusat cluster = rata-rata.

K-Medoids

Pusat cluster = data asli.

Contoh:

Data:

5

6

7

100

K-Means:

Centroid bisa jadi:

29.5

padahal tidak ada di data.

K-Medoids:

Pusat cluster harus salah satu data:

5 atau 6 atau 7 atau 100

Kelebihan:

✅ Lebih tahan outlier

Karena tidak memakai rata-rata.

6. DBSCAN

Ini algoritma yang sangat berbeda.

Tidak perlu menentukan K.

DBSCAN mencari:

daerah yang padat.

Misal:

● ● ● ●

● ● ●

●

●

Kelompok padat:

● ● ● ●

● ● ●

menjadi cluster.

Titik yang sendirian:

●

dianggap noise.

Parameter DBSCAN

eps (ϵ)

Jarak maksimum tetangga.

MinPts

Jumlah minimal tetangga.

Misalnya:

MinPts = 5

Kalau suatu titik punya 5 tetangga dekat:

→ masuk cluster.

Kalau tidak:

→ noise.

Kelebihan DBSCAN

- ✓ Tidak perlu menentukan K
 - ✓ Bisa mendeteksi noise
 - ✓ Bisa menemukan bentuk cluster aneh
-

Kekurangan DBSCAN


- ✗ Sulit menentukan ϵ
 - ✗ Kurang efisien pada data sangat besar
-

7. Mean Shift

Ide dasarnya:

Bayangkan setiap titik bergerak menuju daerah yang paling padat.

Contoh:



Titik-titik akan “bergeser” menuju pusat kepadatan.
Akhirnya terbentuk cluster.

Kelebihan

- ✓ Tidak perlu menentukan K
- ✓ Bisa menemukan bentuk cluster kompleks

Kekurangan

- ✗ Lambat
- ✗ Sensitif terhadap ukuran kernel (window)

Ringkasan Hafalan Cepat

Algoritma	Ciri Utama
Hierarchical	Membentuk pohon (dendrogram)
K-Means	Berdasarkan centroid, perlu K

K-Medoids	Mirip K-Means tapi pusatnya data asli
DBSCAN	Berdasarkan kepadatan (density)
Mean Shift	Titik bergerak ke area paling padat

Hafalan 1 Baris

- **K-Means** = kelompok berdasarkan centroid.
- **K-Medoids** = K-Means yang tahan outlier.
- **DBSCAN** = mencari daerah padat dan noise.
- **Hierarchical** = membuat pohon cluster.
- **Mean Shift** = mencari pusat kepadatan secara otomatis.

Kalau setelah ini kamu paham dasar clustering, langkah berikutnya yang paling penting adalah memahami **perbedaan K-Means vs DBSCAN vs Hierarchical**, karena itu yang paling sering muncul di soal dan wawancara.