

Bagus. Materi **Feature Engineering** ini sebenarnya menjawab pertanyaan:

“Sebelum data masuk ke model, apa yang harus kita lakukan supaya model lebih mudah belajar?”

Bayangkan model machine learning itu seperti mahasiswa yang akan ujian.

Kalau dikasih data berantakan:

- ada data kosong
- ada tulisan
- ada angka dengan skala berbeda
- ada data aneh

maka model akan sulit belajar.

Feature Engineering bertugas **membersihkan dan memperbaiki data sebelum training**.

1. Apa itu Feature Engineering?

Feature Engineering adalah proses:

- memilih fitur yang penting
- mengubah fitur
- membuat fitur baru
- membersihkan fitur

agar model lebih akurat.

Contoh:

Dataset rumah:

Luas	Kamar	Harga
100	2	500 jt
200	4	1 M

Kita bisa membuat fitur baru:

Luas per kamar

=

$\text{Luas} / \text{Kamar}$

Fitur baru ini kadang lebih informatif daripada fitur asli.

2. Feature Selection (Pemilihan Fitur)

Tujuannya:

Memilih fitur yang penting dan membuang yang tidak penting.

Misal:

Nama	No HP	Umur	Gaji	Beli Rumah
------	-------	------	------	------------

Untuk prediksi beli rumah:

Mungkin berguna:

✓ Umur

✓ Gaji

Tidak berguna:

✗ Nama

✗ Nomor HP

Karena nama dan nomor HP tidak punya hubungan dengan pembelian rumah.

Kenapa perlu Feature Selection?

Karena terlalu banyak fitur bisa menyebabkan:

Overfitting

Model menghafal data.

Training lambat

Komputasi lebih besar.

Banyak noise

Model bingung membedakan informasi penting dan tidak penting.

3. Encoding

Ini yang pernah kita bahas sebelumnya.

Komputer hanya memahami angka.

Misalnya:

Warna
Merah
Biru
Hijau

Tidak bisa langsung dipakai model.

Harus diubah menjadi angka.

Label Encoding

Merah = 0

Biru = 1

Hijau = 2

One Hot Encoding

Lebih aman.

Warna	Merah	Biru	Hijau
Merah	1	0	0
Biru	0	1	0
Hijau	0	0	1

Ini yang paling sering dipakai.

4. Binning

Binning adalah mengubah angka kontinu menjadi kategori.

Misal umur:

18

19

20

21

22

...

Diubah menjadi:

Umur	Kategori
------	----------

18-25	Muda
26-40	Dewasa
>40	Tua

Kenapa dilakukan?

Kadang pola lebih mudah terlihat.

Contoh:

Daripada:

`umur = 37`

lebih mudah:

`umur = Dewasa`

5. Scaling

Ini sangat penting.

Misalnya:

Umur	Gaji
20	5.000.000
30	10.000.000

Perhatikan:

`Umur ≈ puluhan`

`Gaji ≈ jutaan`

Kalau langsung dipakai:

Model akan menganggap gaji jauh lebih penting.

Padahal belum tentu.

Solusi

Lakukan scaling.

Normalisasi

Mengubah nilai menjadi rentang:

0 sampai 1

Contoh:

20 $\rightarrow$ 0.2

30 $\rightarrow$ 0.3

Standardisasi

Mengubah data menjadi:

mean = 0

std = 1

Biasanya dipakai pada:

- SVM
 - KNN
 - Neural Network
-

Kapan scaling penting?

Sangat penting untuk:

✓ KNN

✓ SVM

✓ K-Means

Karena mereka menghitung jarak.

6. Outlier

Outlier = data yang sangat berbeda dari data lainnya.

Contoh:

Nilai siswa:

70

75

80

85

78

82

500

500 adalah outlier.

Kenapa berbahaya?

Karena dapat menggeser rata-rata.

Misalnya:

Mayoritas sekitar:

80

Tapi karena ada:

500

Rata-rata jadi sangat besar.

Cara mendeteksi

Biasanya menggunakan:

- Boxplot
 - Histogram
 - IQR
-

Apa yang dilakukan?

Kadang:

✓ dihapus

atau

✓ diperbaiki

atau

✓ dipertahankan jika memang valid

7. Imbalanced Dataset

Ini sering keluar di soal.

Misalnya:

Deteksi penipuan.

Kelas	Jumlah
Normal	9500
Fraud	500

Model bisa saja selalu menjawab:

Normal

dan mendapat:

95% akurasi

Padahal tidak pernah menemukan fraud.

Ini disebut Imbalanced Dataset

Jumlah kelas tidak seimbang.

8. Oversampling

Tujuan:

Menambah data minoritas.

Misalnya:

Sebelum:

Normal = 1000

Fraud = 100

Sesudah:

Normal = 1000

Fraud = 1000

Cara sederhana

Duplikasi data minoritas.

Fraud A

Fraud B

↓

Fraud A

Fraud B

Fraud A

Fraud B

Kelemahan

Bisa menyebabkan overfitting.

Karena hanya meng-copy data.

9. Undersampling

Kebalikan oversampling.

Mengurangi kelas mayoritas.

Sebelum:

Normal = 1000

Fraud = 100

Sesudah:

Normal = 100

Fraud = 100

Masalahnya:

Kita kehilangan banyak data.

10. SMOTE

Ini teknik yang sangat sering ditanya.

SMOTE = Synthetic Minority Over-sampling Technique

Bedanya dengan Oversampling biasa:

Oversampling biasa

Meng-copy data.

A
A
A

SMOTE

Membuat data baru.

Misal:

Data minoritas:

$A = (10, 20)$

$B = (12, 24)$

SMOTE membuat titik baru di antaranya:

$C = (11, 22)$

Jadi:

A

B

menjadi:

A

B

C

Keuntungan SMOTE

- ✓ Menambah variasi data
- ✓ Mengurangi overfitting
- ✓ Sangat populer untuk data tidak seimbang

Ringkasan Hafalan Cepat

Teknik	Fungsi
Feature Selection	Memilih fitur penting
Encoding	Mengubah kategori menjadi angka
Binning	Angka → kategori
Scaling	Menyamakan skala fitur
Outlier Handling	Menangani data ekstrem
Oversampling	Menambah kelas minoritas
Undersampling	Mengurangi kelas mayoritas
SMOTE	Membuat data sintetis minoritas

Hafalan Super Singkat

- **Feature Selection** → pilih fitur penting.
- **Encoding** → teks jadi angka.
- **Binning** → angka jadi kategori.
- **Scaling** → samakan skala.
- **Outlier** → data yang terlalu ekstrem.
- **Oversampling** → tambah minoritas.
- **Undersampling** → kurangi mayoritas.
- **SMOTE** → buat data minoritas baru secara sintetis.

Kalau dilihat dari seluruh materi yang sudah kamu pelajari (Klasifikasi → Regresi → Clustering → Feature Engineering), bagian yang paling sering membuat mahasiswa bingung biasanya perbedaan kapan memakai normalisasi, standardisasi, encoding, oversampling, dan SMOTE dalam satu alur machine learning. Itu bisa saya jelaskan dengan satu contoh proyek dari awal sampai akhir.