

UTS Data Science

Cakupan Materi

BAB 1 Pengantar Data Science

BAB 2 Python untuk Data Science (NumPy dan Pandas)

BAB 3 Data Cleaning dan Data Preprocessing

BAB 4 Statistik Dasar untuk Data Science

BAB 5 Visualisasi Data

BAB 6 Exploratory Data Analysis (EDA)

BAB 7 Machine Learning Dasar

BAB 8 Regresi Linear dan Regresi Logistik

BAB 9 Decision Tree, KNN, dan Naive Bayes

BAB 10 Clustering dengan K-Means dan Hierarchical Clustering

Bagian A — Konsep Dasar

Soal 1

Jelaskan pengertian Data Science dan hubungan antara Data Science, Machine Learning, dan Artificial Intelligence.

Soal 2

Bandingkan:

Data

Informasi

Knowledge

Soal 3

Jelaskan perbedaan:

Data Scientist

Data Analyst

Data Engineer

Soal 4

Jelaskan konsep Big Data dan karakteristik 5V.

Soal 5

Bandingkan:

Structured Data

Semi Structured Data

Unstructured Data

Soal 6

Jelaskan seluruh tahapan dalam Data Science Lifecycle.

Soal 7

Mengapa Data Cleaning menjadi salah satu tahap terpenting dalam proyek Data Science?

Soal 8

Jelaskan perbedaan:

Supervised Learning

Unsupervised Learning

Soal 9

Berikan masing-masing tiga contoh kasus:

Classification

Regression

Clustering

Soal 10

Apa yang dimaksud dengan Feature dan Label?

Bagian B — Python, NumPy, dan Pandas

Soal 11

Jelaskan fungsi NumPy dalam Data Science.

Soal 12

Bandingkan:

List Python

Array NumPy

Soal 13

Apa fungsi:

shape

size

ndim

dtype

Soal 14

Jelaskan perbedaan:

Series

DataFrame

Soal 15

Apa fungsi:

`head()`

`tail()`

`info()`

`describe()`

Soal 16

Bagaimana cara membaca file CSV menggunakan Pandas?

Soal 17

Bagaimana cara memilih satu kolom dan beberapa kolom pada DataFrame?

Soal 18

Bagaimana cara melakukan filtering data menggunakan Pandas?

Soal 19

Apa fungsi:

`groupby()`

Soal 20

Jelaskan manfaat Pandas dalam proses analisis data.

Bagian C — Data Cleaning dan Statistik

Soal 21

Apa yang dimaksud dengan Missing Value?

Soal 22

Sebutkan dan jelaskan tiga metode penanganan Missing Value.

Soal 23

Bagaimana cara mendeteksi data duplikat?

Soal 24

Apa yang dimaksud dengan Outlier?

Soal 25

Jelaskan metode IQR untuk mendeteksi outlier.

Soal 26

Bandingkan:

Label Encoding

One Hot Encoding

Soal 27

Apa tujuan Feature Scaling?

Soal 28

Jelaskan perbedaan:

Normalisasi

Standardisasi

Soal 29

Bandingkan:

Mean

Median

Modus

Soal 30

Apa fungsi:

Range

Varians

Standar Deviasi

Soal 31

Apa yang dimaksud dengan Korelasi?

Soal 32

Mengapa korelasi tidak selalu berarti kausalitas?

Soal 33

Apa yang dimaksud dengan Distribusi Normal?

Soal 34

Jelaskan konsep:

Kuartil

IQR

Soal 35

Mengapa statistik menjadi fondasi penting dalam Data Science?

Bagian D — Visualisasi dan EDA

Soal 36

Apa tujuan utama visualisasi data?

Soal 37

Kapan menggunakan:

Line Chart

Bar Chart

Pie Chart

Soal 38

Apa fungsi:

Histogram

Scatter Plot

Box Plot

Soal 39

Apa kelebihan Seaborn dibanding Matplotlib?

Soal 40

Apa fungsi Heatmap?

Soal 41

Apa yang dimaksud dengan EDA?

Soal 42

Mengapa EDA dilakukan sebelum Machine Learning?

Soal 43

Bagaimana cara mendeteksi Missing Value saat EDA?

Soal 44

Apa fungsi Correlation Matrix?

Soal 45

Apa yang dimaksud dengan Insight?

Bagian E — Machine Learning

Soal 46

Apa yang dimaksud dengan Training Data dan Testing Data?

Soal 47

Mengapa dataset perlu dibagi menjadi data training dan testing?

Soal 48

Jelaskan perbedaan:

Classification

Regression

Soal 49

Apa yang dimaksud dengan Overfitting?

Soal 50

Apa yang dimaksud dengan Underfitting?

Soal 51

Jelaskan konsep Regresi Linear.

Soal 52

Jelaskan arti setiap komponen pada persamaan:

Soal 53

Apa fungsi MAE, MSE, dan RMSE?

Soal 54

Apa yang dimaksud dengan Regresi Logistik?

Soal 55

Apa fungsi Sigmoid pada Regresi Logistik?

Soal 56

Mengapa output Sigmoid selalu berada pada rentang 0–1?

Soal 57

Apa fungsi Accuracy dalam evaluasi model klasifikasi?

Soal 58

Bandingkan:

Regresi Linear

Regresi Logistik

Soal 59

Jelaskan konsep dasar Decision Tree.

Soal 60

Apa fungsi:

Entropy

Information Gain
pada Decision Tree?

Soal 61

Jelaskan konsep dasar KNN.

Soal 62

Apa arti nilai K pada algoritma KNN?

Soal 63

Apa fungsi Euclidean Distance pada KNN?

Soal 64

Mengapa KNN sensitif terhadap skala data?

Soal 65

Jelaskan konsep dasar Naive Bayes.

Soal 66

Mengapa algoritma tersebut disebut "Naive"?

Soal 67

Sebutkan tiga penerapan Naive Bayes.

Soal 68

Apa yang dimaksud dengan Clustering?

Soal 69

Mengapa Clustering termasuk Unsupervised Learning?

Soal 70

Jelaskan konsep dasar K-Means.

Soal 71

Apa yang dimaksud dengan Centroid?

Soal 72

Jelaskan langkah-langkah algoritma K-Means.

Soal 73

Apa fungsi Elbow Method?

Soal 74

Apa yang dimaksud dengan Hierarchical Clustering?

Soal 75

Bandingkan:

Agglomerative Clustering

Divisive Clustering

Bagian F — Analisis

Soal 76

Analisis dampak jika data yang mengandung banyak Missing Value digunakan langsung untuk Machine Learning.

Soal 77

Analisis dampak jika visualisasi data dibuat dengan grafik yang tidak sesuai.

Soal 78

Analisis hubungan antara:

Data Cleaning

EDA

Machine Learning

Soal 79

Menurut Anda, algoritma mana yang lebih mudah dipahami:

Decision Tree

KNN

Naive Bayes

Jelaskan alasannya.

Soal 80

Menurut Anda, tahap paling penting dalam proyek Data Science adalah:

Data Collection

Data Cleaning

EDA

Modeling

Berikan alasan yang logis dan didukung konsep yang telah dipelajari.

UTS selesai.

Selanjutnya: BAB 11 — Evaluasi Model Machine Learning dan Confusion Matrix.